

Численные методы, Весна 2021 ВШЭ. Задание 10.^a

1. **Восстановление зашумлённого изображения (30)** Возьмите файл `data_5_1.npz`, содержащий матрицы A и C (изображение и фильтр) и откройте его, используя `numpy`:

```
with np.load('data.npz') as data:
    A, C = data['A'], data['C']
```

Для работы с изображением нам будет удобно выстраивать элементы матрицы A в вектор–столбец a :

```
def mat2vec(A):
    h, w = A.shape
    a = np.zeros(h*w, dtype=A.dtype)
    A = np.flipud(A)
    for i, row in enumerate(A):
        a[i*w:i*w+w] = row
    return a
```

так что обратное преобразование – от вектора a в матрицу A осуществляется с помощью функции

```
def vec2mat(a, shape):
    h, w = shape
    A = np.zeros(shape, dtype=a.dtype)
    for i in range(h):
        A[i, :] = a[i*w:i*w+w]
    return np.flipud(A)
```

Изображение, содержащееся в матрице A получено из некоторого оригинала A_0 путем свёртки его с фильтром C и добавлением шума. Фильтр C осуществляет ‘размытие’ изображения, одновременно меняя его размер от 16×51 к 25×60 . Используя соответствующие вектора a и a_0 , эту операцию можно записать так

$$a_0 \rightarrow a = Ca_0 + \epsilon,$$

где ϵ - вектор, состоящий из нескоррелированных случайных величин из нормального распределения. Ваша задача состоит в том, чтобы располагая зашумленным изображением A и фильтром C , восстановить исходное изображение A_0 .

- (5) Постройте изображение, содержащееся в A (у вас должен получиться Рис. 1).
 - (7) Исследуйте действие фильтра C на изображения: составьте (на свой выбор) матрицу, и проверьте, что с соответствующим изображением делает фильтр C . Вам понадобятся операции `a = mat2vec(A)` и `A0 = vec2mat(a0, shape)` для перехода от матричного к векторному представлению и обратно.
 - (8) Наивный способ восстановить изображение A_0 по изображению A состоит в том, чтобы решить систему $a = Ca_0$ относительно вектора a_0 . Какой является эта система: недо- или переопределённой? Используйте SVD матрицы C чтобы найти a_0 и постройте соответствующее изображение A_0 .
 - (10) Для того, чтобы улучшить результат, поэкспериментируйте с количеством удержанных собственных значений при решении системы уравнений в предыдущем пункте. Что находится на изображении A_0 ?
2. **Ранжирование веб–страниц (35)** Одна из самых известных задач о вычислении собственных векторов – задача о ранжировании n веб-страниц. Подход, который вам нужно будет реализовать в этой задаче, был одним из главных в работе Google на раннем этапе. Всё, что мы собираемся использовать – структуру

^a Дополнительно указаны: (количество баллов за задачу)[имя задачи на nbgrader]

взаимных ссылок между страницами. **PageRank** определяется рекурсивно: важность i -й страницы определяется как среднее значение важностей всех страниц, которые ссылаются на i -ю. Обозначим важность i -й страницы p_i , тогда это определение может быть записано в виде линейной системы:

$$p_i = \sum_j \frac{p_j}{L(j)} l_{ij},$$

где $l_{ij} = 1$ если j -я страница ссылается на i -ю (в противном случае $l_{ij} = 0$), а $L(j)$ – количество исходящих ссылок со страницы j . Система может быть переписана в виде задачи на собственное значение:

$$p = Gp, \quad G_{ij} = \frac{l_{ij}}{L(j)}.$$

Если в графе есть ‘подвешенные’ узлы (все элементы какого-то столбца равны нулю), то весь столбец заполняется числом $1/n$. Наконец, вводится параметр $0 < \beta < 1$ так что матрица G заменяется на

$$G \rightarrow \beta G + \frac{1-\beta}{n} ee^T,$$

где e – вектор, состоящий из единиц. Обратите внимание, что задача свелась к нахождению собственного вектора p матрицы G , отвечающего собственному значению 1. Можно показать [4], что 1 – максимально возможное собственное значение матрицы G .

- (4) Придумайте самостоятельно небольшой граф связности (10 узлов), постройте соответствующие матрицы l и G и найдите численно собственный вектор, отвечающий **PageRank**.
- (1) Скачайте файл, в котором представлен ориентированный граф, узлы которого составляют страницы stanford.edu, а направленные рёбра – ссылки между ними (граф задан матрицей смежности l). Распакуйте архив и загрузите его:

```
from scipy import sparse
def dataset2csr(filename, nodes, edges):
    rows = []; cols = []
    with open(filename, 'r') as f:
        for line in f.readlines()[4:]:
            o, d = (int(x)-1 for x in line.split())
            rows.append(d)
            cols.append(o)
    return(sparse.csr_matrix(([True]*edges, (rows, cols)), shape=(nodes, nodes)))

l = dataset2csr(filename='web-Stanford.txt', nodes = 281903, edges=2312497)
```

- (6) Найдите **PageRank** для матрицы из предыдущего пункта. Для этого реализуйте степенную итерацию для нахождения собственного вектора, отвечающего максимальному собственному значению G . Возьмите $\beta = 0.8$.
- (9) Итерируйте до тех пор, пока 1-норма изменения вектора-кандидата не станет меньше 10^{-4} . Сколько итераций понадобилось?
- (5) Какому собственному значению отвечает найденный вектор и у какого узла наибольший **PageRank**?
- (10) Докажите утверждение (*).

3. (20) Рассмотрите матрицу A размера 32×32 , задаваемую следующей формулой:

$$A_{ij} = -\delta_{i,j} + \delta_{i,j-1} + \delta_{i,j-2}.$$

- (5) Найдите спектр матрицы A .
- (5) Используя функцию `scipy.linalg.expm`, постройте $\|e^{At}\|_2$ как функцию t на интервале $0 \leq t \leq 50$.
- (10) Используя (без доказательства) эквивалентность утверждений i и iii из задачи 26.1 Trefethen, Вау, изобразите в комплексной плоскости множество σ_ϵ [см. определение в Задаче 3 листка 4] для $\epsilon = 10^{-i}$, $i = 1, \dots, 5$.

4. (15) Постройте интерполяцию функций

$$y_1(x) = \sin(6x) + \sin(60e^x), \quad y_2(x) = \frac{1}{1 + 1000(x + 0.5)^2} + \frac{1}{\sqrt{1 + 1000(x - 0.5)^2}}$$

на отрезке $[-1, 1]$ полиномами Чебышева. Постройте зависимость ошибки приближения от количества узлов. Сколько узлов нужно удерживать в каждом из этих случаев для получения достаточно точного приближения?

5. (30) **Изотерма реального газа** Рассмотрим изотермы реального газа, описываемого уравнением вандер-Ваальса

$$p = \frac{RT}{V - b} - \frac{a}{V^2}.$$

Здесь p – давление газа, V – объем, T – температура, а a , b и R – постоянные. Видно, что при постоянной температуре T ниже определенной (так называемой критической) температуры, зависимость давления от объема становится немонотонной. Физически эта область – область сосуществования жидкость-газ, а часть изотермы, на которой объем растет при увеличении давления является нефизической. Фактически же давление остается постоянным во всей области сосуществования, причем положение горизонтального участка изотермы определяется правилом Максвелла и геометрически находится из равенства площадей участков изотермы. (см. напр., Д.В. Сивухин *Термодинамика* или R. Swendsen, *An introduction to statistical mechanics and thermodynamics* или любой иной учебник по термодинамике). Построить изотермы газа с учетом конструкции Максвелла, т.е. вычислить положение горизонтального участка изотермы *Указание: Первым действием найти критические параметры (10) – т.е. найти точку, в которой обращаются в ноль первая и вторая производные давления по объему – и переписать уравнение состояния в безразмерных единицах (20).*

6. (30) **Прямоугольная яма II** Рассмотрим квантовую частицу в прямоугольной яме. В задаче SquareWell (листок 7) были найдены собственные значения и собственные функции гамильтониана. Также были построены – сеточным методом – собственные функции частицы с дополнительным возмущающим потенциалом вида $V(x) = \gamma x(x - a)$. Теперь рассмотрим задачу в базе собственных функций невозмущенного гамильтониана (просто прямоугольной ямы) и найдите уровни энергии и собственные функции возмущенной системы с потенциалом $V(x)$. Сравните результаты с решением задачи сеточным методом. Сколько собственных значений невозмущенной системы нужно взять для того, чтобы получить значение энергий первых трех состояний с точностью 1%? Для малых значений γ сравните результаты с теорией возмущений (см. например Ландау-Лифшиц, Квантовая механика).

7. (30) **Одномерная диффузия** Рассмотрим простейшее одномерное уравнение диффузии функции распределения частиц по импульсам $f(p, t)$:

$$\frac{\partial f}{\partial t} = \frac{\partial}{\partial p} \left(D \frac{\partial f}{\partial p} \right) \quad (1)$$

В тривиальном случае, когда $D = \text{const}$, оно имеет аналитическое решение.

(5) Получить аналитическое решение уравнения (1) в случае, когда $D = 1$, $f(t = 0, p) = \delta(p)$. *Указание: перейти к Фурье-пространству, рассмотреть уравнение на Фурье-образ функции распределения.*

(10) Численно решить уравнение (1) при тех же условиях, что в предыдущем пункте на временном интервале $t = [0, 100]$.

К решению уравнения диффузии можно подойти и с другой стороны: при диффузии траектория каждой частицы в фазовом пространстве является случайной, т.е. для ее описания можно использовать модель случайного блуждания. Можно показать, что импульс каждой частицы будет являться случайной величиной и его изменение в каждый момент времени можно описать формулой:

$$p(t + dt) = p(t) + \sqrt{2D}W_t \quad (2)$$

где $W_t = \varepsilon\sqrt{dt}$ – изменение Винеровского процесса, $\varepsilon \sim N(0, 1)$ – нормально-распределенная случайная величина.

(10) Напишите программу, которая будет моделировать случайные фазовые траектории $\sim 10^6$ частиц и позволит проследить эволюцию функции распределения во времени. Для этого нужно: 1) задать ансамбль частиц с импульсами, удовлетворяющими начальному условию, 2) задать шаг по времени, 3) для каждой частицы на каждом шаге сгенерировать нормальное случайное число и рассчитать изменение импульса, 4) собрать функцию распределения частиц, зная импульс каждой частицы (бинировать импульсы и посчитать, какое количество частиц попало в каждый бин).

(5) Сравнить все три полученных решения.

8. (30) **Metropolis-Hastings** В 1986 г. космический шатл Challenger взорвался во время старта, семь астронавтов погибли. Оказалось, что взрыв был вызван разрывом резиновых элементов (O-ring failure), скрепляющих детали обшивки. Авария произошла при относительно низкой температуре (31° F , или 0° C), что наводит на мысль о повышении вероятности аварии с понижением температуры (резина “задубела”). Данные с предыдущих (к счастью, безаварийных) запусков по наличию факта разрыва резиновых элементов (O-ring failures) представлены в файле **Challenger.csv**. Первая колонка – индикатор ($1/0$ = есть/нет O-ring failures), вторая колонка отвечает температуре окружающей среды T_i при i -ом старте.

(a) (5) Рассмотрите модель логистической регрессии для аппроксимации вероятности O-ring failure, т.е.

$$\Pr(Y_i = 1|T_i) \stackrel{\text{def}}{=} p(T_i) = \frac{e^{\alpha + \beta T_i}}{1 + e^{\alpha + \beta T_i}} \quad (3)$$

Найти оценки параметров α и β , минимизируя квадрат ошибки.

- (b) (5) Применяя формулу Байеса, записать апостериорное совместное распределение величин α и β , используя равномерные априорные распределения (uniform priors), т.е.

$$p(\alpha, \beta) = c \mathcal{L}(T_1, \dots, T_n; \alpha, \beta) p_0(\alpha) g_0(\beta) \quad (4)$$

где $p_0(\alpha) \sim \text{Unif}(0, 30)$, $g_0(\beta) \sim \text{Unif}(-1, 1)$ – плотности равномерного закона. Нормировочная константа c не важна.

Указание: пусть при T_1 индикатор O-ring failure $y_1 = 1$, при T_2 индикатор $y_2 = 0$ и т.д. Тогда функция правдоподобия начинается так: $\mathcal{L}(T_1, \dots, T_n; \alpha, \beta) = p(T_1) \times (1 - p(T_2)) \times \dots$, т.к. (3) есть вероятность $Y = 1$ при температуре T_1 , а $1 - p(T_2)$ есть вероятность $Y = 0$ при температуре T_2 .

- (c) (10) Реализуйте алгоритм Метрополиса-Гастингса для генерации величин из распределения (4).
 (d) (5) Запустите соответствующую марковскую цепь длины не менее 50000 и получите предсказание (т.е. среднее) вероятности O-ring failure при 60, 50 и 40 °F. Найти также с.к.о. указанных вероятностей и построить гистограммы данных вероятностей.
 (e) (3) Построить маргинальные распределения (гистограммы) для α и β .
 (f) (2) Предложите какую-либо диагностику, удостоверяющую, что марковская цепь вышла на стационарный режим.

Все гистограммы должны иметь по крайней мере 15 столбцов.

9. (15) **Условие излучения** Рассматривается монохроматическая плоская волна $e^{ikx - i\omega t}$, распространяющаяся в положительном направлении оси x . После отделения времени уравнение для пространственной части имеет вид

$$\frac{d^2 u}{dx^2} + k^2 u = 0 \quad (5)$$

- (a) Рассмотрите указанное уравнение на отрезке $[0, 1]$. На левом конце поставьте условие падающей волны, $u(0) = e^{ikx}|_{x=0} = 1$. На правом конце поставьте т.н. условие излучения,

$$\left(\frac{du}{dx} - iku \right) \Big|_{x=1} = 0 \quad (6)$$

- (b) (1) Попытайтесь объяснить логику условия (6)
 (c) (10) Дискретизируйте уравнение (5) и, главное, условие излучения (6) со **вторым** порядком точности. Указание: с уравнением проблем нет, вспомните задание по y -нию Шредингера. С условием (6) наиболее простой подход – использовать равномерную сетку с узлами, сдвинутыми относительно концов интервала на полшага. При таком подходе не забудьте записать условие на левом конце $x = 0$ со вторым порядком точности (это несложно).

- (d) **(2)** Решите соответствующую трехдиагональную систему в комплексных числах. Сравните полученное решение с точным e^{ikx} на двух последовательных сетках с шагами, отличающимися в два раза. Во сколько раз упадет ошибка на мелкой сетке по сравнению с грубой? Волновое число задайте самостоятельно, например, $k = 1$.
- (e) **(2)** Поставьте на правом конце $x = 1$ какое-нибудь другое произвольное условие, например $u(1) = 1$. Сравните полученное решение с точным.